



西安建築科技大学

实验报告

课程名称: 编译原理

实验名称: 词法分析程序设计

院 (系): 信控学院

专业班级: 计算机 2203

姓 名: 梁桐

学 号: 2209060322

指导教师: 叶 娜

2025 年 3 月 26 日



实验一 词法分析程序设计

一、实验目的

理解词法分析器的任务和工作原理；掌握词法分析器的构建过程，并能够针对给定语言的词法规则，使用某种高级编程语言实现其词法分析器。

二、实验内容

1. 给定表 1 所示的一个简单语言的单词符号表，其中，标识符是以字母开头、以字母和数字组成的任意符号串，常数为整数，即以数字组成的符号串。请完成以下任务：

(1) 画出识别该语言词法单元的状态转换图；

(2) 依据状态转换图，设计并编制词法分析程序，实现从输入源程序中，识别出各类单词，即关键字、标识符、常数、运算符、界符五大类，并输出各个单词的种别码和单词符号自身的值。

(3) 设计恰当的测试用例对各类单词的识别进行测试。

表 1 某简单语言的词法规则

单词符号	种别码	单词符号	种别码
void	101	>=	207
main	102	<	208
int	103	<=	209
char	104	==	210
if	105	<>	211
else	106	++	212
for	107	--	213
while	108	(301
+	201)	302
-	202	{	303
*	203	}	304
/	204	；	305
=	205	标识符	400
>	206	常数	500

2. 在线学习 LEX/FLEX 相关内容，并整理记录相关笔记。

推荐学习网址：<https://www.educoder.net/shixuns/x452vfi6/challenges>

三、实验设备

计算机、编程语言集成开发环境。

四、实验原理（或程序框图）及步骤

1、设计构思



设计实验方案：

根据实验指导书，明确实验需求，确定词法分析器的功能模块。

确定输入输出方式：支持文件输入与控制台输入两种模式。

增加错误检测功能：当扫描到无法识别的词素时，输出错误提示及行号，错误信息以红色显示。

模块划分：

输入处理模块：实现文件输入和控制台输入选择，负责读取源代码。

分词模块：逐行扫描源代码，根据字符类型拆分成一个个词素（Token 字符串）。

词法识别模块：针对每个词素，利用映射表及规则判断其类型（关键字、运算符、界符、标识符、数字常量）。

错误处理模块：检测无法识别的词素，并报告错误行号（错误信息以红色显示）。

输出模块：将每个 Token 的种别码和词素输出到控制台。

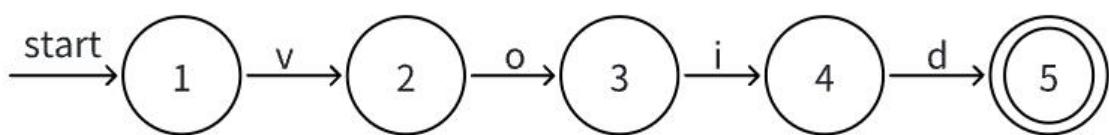
2. 正则表达式和状态转换图

关键字的正则表达式与状态转换图

关键字：void

正则表达式：void

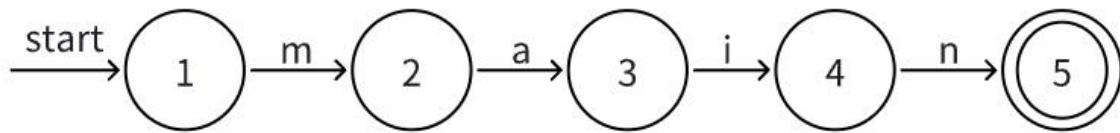
状态转换图：



关键字：main

正则表达式：main

状态转换图：



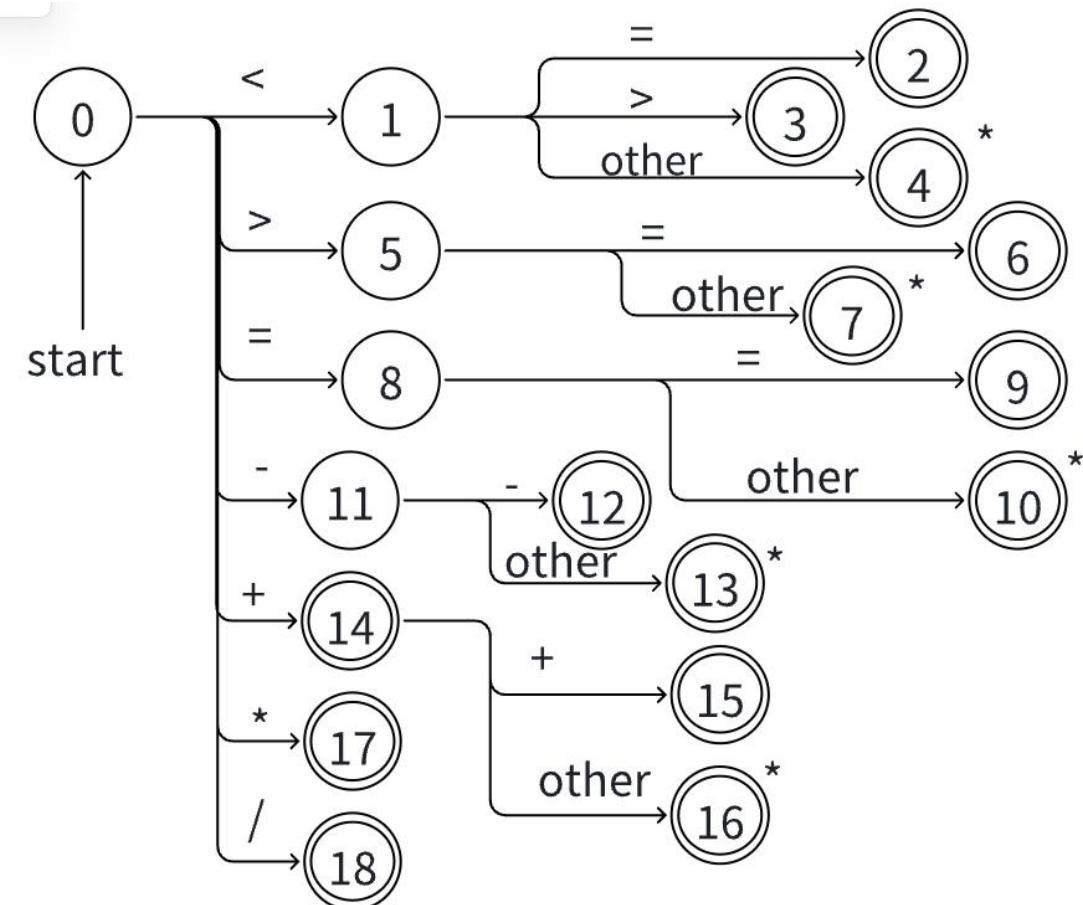
剩余的关键字以此类推。

运算符的正则表达式：



<|<=|<>|>|=|=|==|+|++|-|-

运算符的状态转换图:



标识符的正则表达式:

letter(letter|digit)*

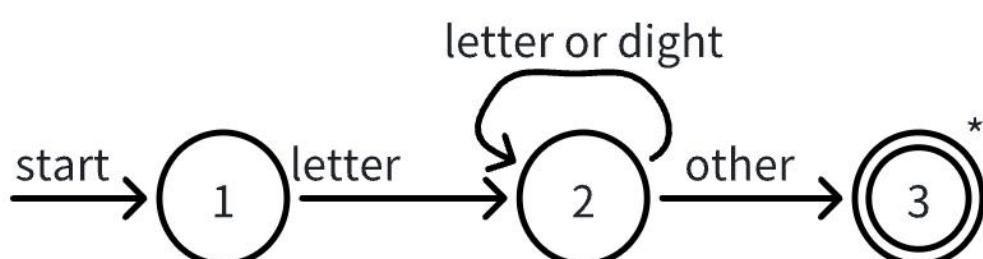
词法单元模式:

digit->[0-9]

digits->digit+

letter->[A-Za-z]-

标识符的状态转换图:

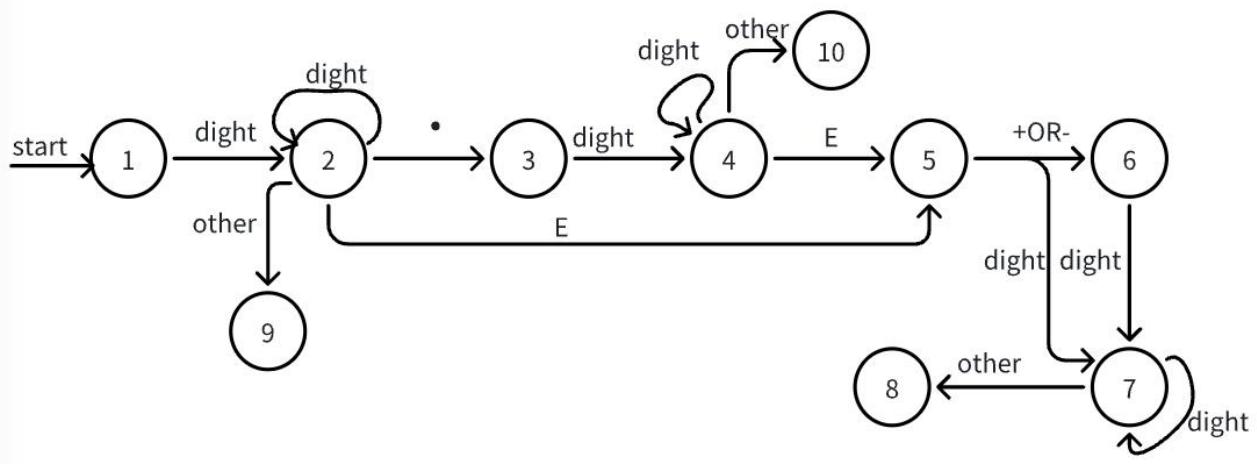


常数的正则表达式:

digits(.digits)?(E[+-]?)?dights)?



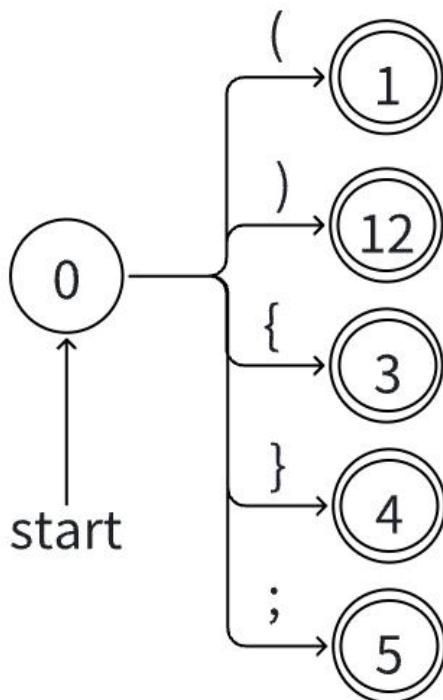
常数的状态转换图:



界符的正则表达式:

$(\{\})$;

界符的状态转换图:



3. 数据结构

映射表 (map)

关键字表: `map<string, int> keywordMap` 用于存储关键字及其对应种别码。

运算符表: `map<string, int> opMap` 用于存储运算符 (含多字符) 及其种别码。

界符表: `map<char, int> delimiterMap` 用于存储单字符界符及其种别码。

Token 结构体

用于存储每个词法单元的识别结果, 包括种别码和词素字符串。



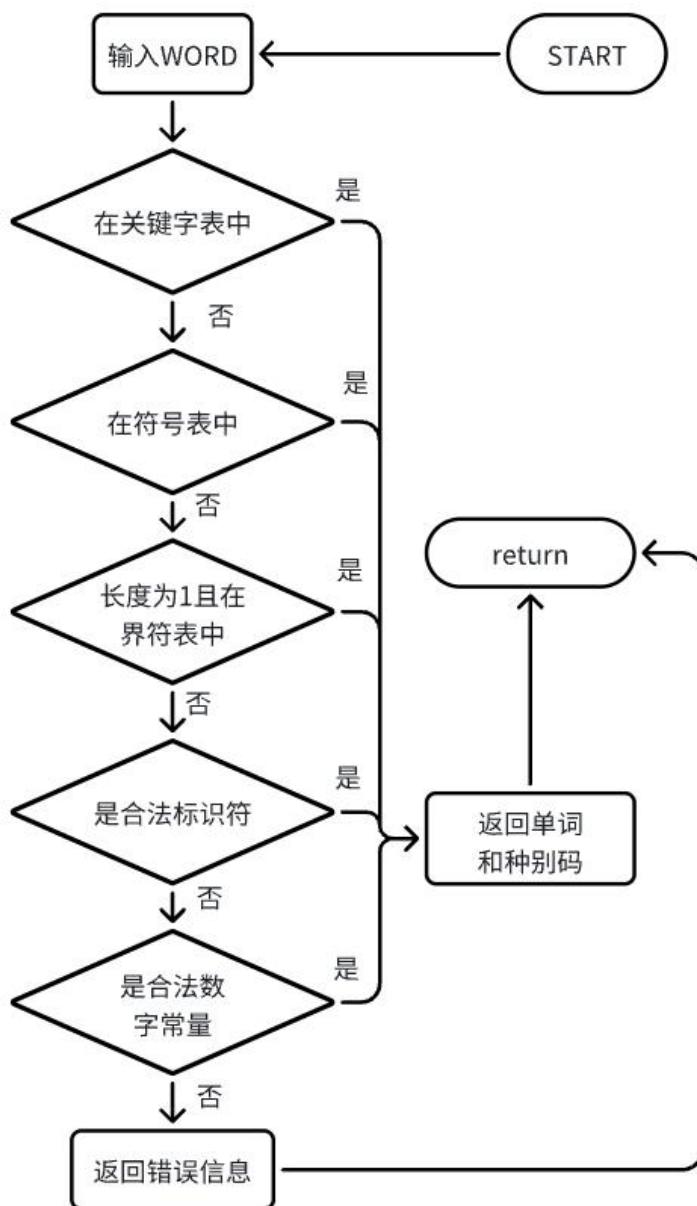
字符串向量

在分词模块中，使用 `vector<string>` 存储一行拆分出的各个词素。

辅助变量

如行号计数器、字符位置指针等。

4. 关键流程



功能说明

接收一个单词（词素字符串），按照以下顺序进行判断并返回一个 Token:

关键字判断：如果 word 存在于 keywordMap 中，则填充 Token 的 code 与 lexeme 并返回。

运算符判断：检查 opMap 是否包含该字符串。



界符判断：如果 word 长度为 1，并且在 delimiterMap 中，返回对应 Token。

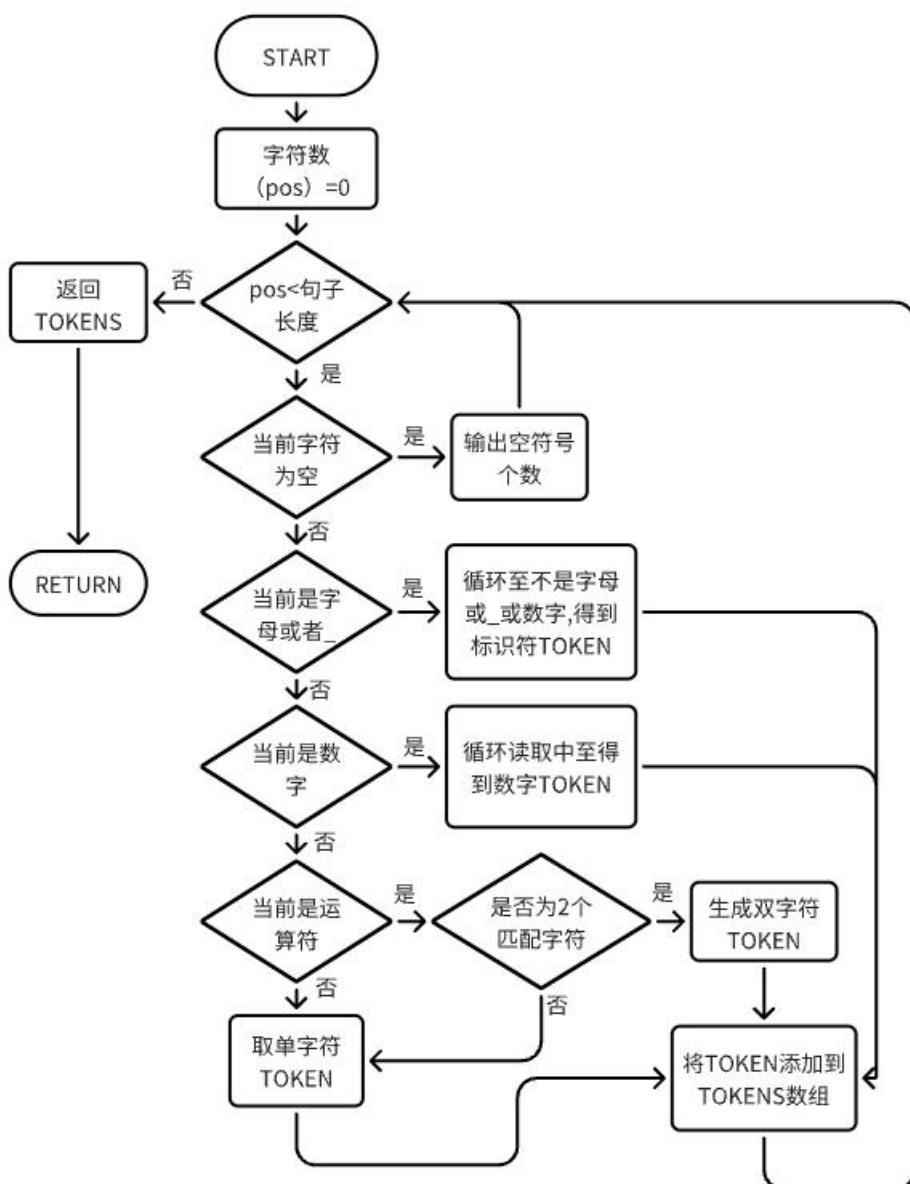
标识符判断：判断 word 是否以字母或下划线开头，并且后续字符只能是字母、数字或下划线（注意这里修改过，允许标识符包含数字）。

数字常量判断：检测是否为数字常量，支持整数、小数和科学计数法。

使用循环检查每个字符，记录小数点与指数符号出现次数，以及指数后是否允许符号。

如果以上都不匹配，则返回 code = 0，表示无法识别。

分词流程如下：



功能说明

对输入的整行代码进行逐字符扫描，切分成多个词素（token 字符串），并返回一个字符串向量。

过程：



跳过空白符：如果遇到空格或制表符，则统计数量并输出提示（并不放入 tokens 中）。

根据字符类型切分：

如果字符是字母或下划线，连续读取直到遇到非标识符字符，形成一个标识符。

如果是数字，则连续读取形成数字常量。

如果是运算符或界符，则先尝试读取两个字符（以支持 "=="、"<="、"++"、"--"），否则读取单个字符。

其他字符作为单独 token 处理。

5. 程序创新点

(1) 文件识别功能的增强

除了支持基本的控制台输入，软件增加了对 C 语言源代码文件的识别功能。

用户可以选择文件输入模式，软件将自动读取文件内容、逐行扫描并进行词法分析，同时对每一行的词素进行检测和错误提示（错误信息显示为红色，并包含行号）。

这一功能不仅提高了软件的实用性，也更贴近实际编译器的工作流程，为后续集成更多编译器前端模块奠定基础。

(2) 错误检测与反馈

在词法识别过程中，软件能够自动检测无法识别的词素，并及时输出包含错误行号的红色提示信息。

这种实时错误反馈机制，帮助用户快速定位代码中的问题，有助于提高编程调试效率，并且在实验报告中体现出对错误处理的重视与改进。

(3) 跨平台打包与便携性

软件经过打包处理后，实现了跨平台运行（例如在 Windows 和 Linux 系统上均可运行），增强了软件的便携性和实际应用价值。

用户无需额外安装复杂环境即可体验词法分析器的全部功能，这一点在实验成果展示中也具有较高的创新性。

(4) 良好的用户交互设计

软件提供了直观的菜单选择界面，用户可以在文件输入和控制台输入之间自由切换，使得操作更简单、用户体验更佳。

同时，软件对空白符、制表符的处理也做了详细提示，增加了对输入流的透明性，方便用户理解词法分析器的工作原理。

五. 程序源代码

1. 单个词素分析程序

```
Token analyzeToken(const string& word) {
    Token token;
    // 1) 判断是否为关键字
    if (keywordMap.find(word) != keywordMap.end()) {
```



```
token.code = keywordMap[word];
token.lexeme = word;
return token;
}

// 2) 判断是否为运算符
if (opMap.find(word) != opMap.end()) {
    token.code = opMap[word];
    token.lexeme = word;
    return token;
}

// 3) 判断是否为界符（只考虑单字符界符）
if (word.size() == 1 && delimiterMap.find(word[0]) != delimiterMap.end()) {
    token.code = delimiterMap[word[0]];
    token.lexeme = word;
    return token;
}

// 4) 判断是否为标识符
// 标识符要求：首字符为字母或下划线，后续字符可以为字母、数字或下划线
bool isIdentifier = true;
if (!word.empty() && isLetterOrUnderscore(word[0])) {
    for (size_t i = 1; i < word.size(); i++) {
        if (!isLetterOrUnderscore(word[i]) && !isdigit(word[i])) {
            isIdentifier = false;
            break;
        }
    }
} else {
    isIdentifier = false;
}
if (isIdentifier) {
    token.code = 400;
    token.lexeme = word;
    return token;
}

// 5) 判断是否为数字常量（支持整数、小数、科学计数法）
```



```
bool isNumber = true;
int dotCount = 0;
int eCount = 0;
bool afterE = false;
if (word.empty()) isNumber = false;
for (size_t i = 0; i < word.size(); i++) {
    char c = word[i];
    if (isdigit(c)) {
        // 数字正常
    }
    else if (isLetterOrUnderscore(c) && (c != 'e' && c != 'E')) {
        isNumber = false;
        break;
    }
    else if (c == '!') {
        dotCount++;
        if (dotCount > 1 || eCount > 0) {
            isNumber = false;
            break;
        }
    }
    else if (c == 'e' || c == 'E') {
        eCount++;
        if (eCount > 1 || i == 0) {
            isNumber = false;
            break;
        }
        afterE = true;
    }
    else if ((c == '+' || c == '-') && afterE) {
        afterE = false;
    }
    else {
        isNumber = false;
        break;
    }
}
```



```
    }  
    if (isNumber) {  
        token.code = 500;  
        token.lexeme = word;  
        return token;  
    }  
    // 6) 如果均不匹配，则无法识别  
    token.code = 0;  
    token.lexeme = word;  
    return token;  
}
```

说明：该函数依次判断输入的字符串是否为关键字、运算符、界符、标识符或数字常量。如果都不匹配，则返回 code=0。详见实验原理的词素分析流程图。

2. 分词函数代码（将一行分割为多个单词）

```
vector<string> tokenizeLine(const string& line) {  
    vector<string> tokens;  
    size_t pos = 0;  
    while (pos < line.size()) {  
        // 如果遇到空白符或制表符，统计并输出提示，然后跳过  
        if (line[pos] == ' ' || line[pos] == '\t') {  
            int count = 0;  
            while (pos < line.size() && (line[pos] == ' ' || line[pos] == '\t')) {  
                count++;  
                pos++;  
            }  
            cout << "[跳过 " << count << " 个空白符]" << endl;  
            continue;  
        }  
        // 根据当前字符决定分词规则  
        char cur = line[pos];  
        string tokenStr = "";  
        // 如果是字母或下划线，则扫描标识符（允许后续含数字）  
        if (isLetterOrUnderscore(cur)) {  
            while (pos < line.size() && (isLetterOrUnderscore(line[pos]) || isdigit(line[pos]))) {  
                tokenStr.push_back(line[pos]);  
            }
```



```
    pos++;
}

}

// 如果是数字，则扫描数字（包括小数及科学计数法部分）
else if (isdigit(cur)) {
    while (pos < line.size() && (isdigit(line[pos]) || line[pos] == '.' ||
        line[pos] == 'e' || line[pos] == 'E' ||
        ((line[pos] == '+' || line[pos] == '-') && pos > 0 &&
         (line[pos - 1] == 'e' || line[pos - 1] == 'E'))))
    {
        tokenStr.push_back(line[pos]);
        pos++;
    }
}

// 如果是可能的运算符或界符，则先尝试两字符匹配（如 "==", "<=", "++", "--"）
else if (isOpDelimChar(cur)) {
    if (pos + 1 < line.size()) {
        string twoChars;
        twoChars.push_back(line[pos]);
        twoChars.push_back(line[pos + 1]);
        if (opMap.find(twoChars) != opMap.end()) {
            tokenStr = twoChars;
            pos += 2;
        }
    }
    else {
        tokenStr.push_back(cur);
        pos++;
    }
}
else {
    tokenStr.push_back(cur);
    pos++;
}

}

// 否则将当前字符作为单独的 token
else {
```



```
    tokenStr.push_back(cur);
    pos++;
}
tokens.push_back(tokenStr);
}
return tokens;
}
```

说明：本函数逐字符扫描输入行，遇到连续空白符时输出提示（不将空白符加入分词结果），根据字符类型（字母、数字、运算符或界符）将一行文本拆分成若干个词素，并返回一个字符串向量。详见实验原理的分词程序流程图。

3. 主函数代码（控制台函数）

```
int main() {
    while (true) {
        cout << "请选择输入模式: \n1. 文件输入\n2. 控制台输入\n3. 退出程序" << endl;
        int mode = 0;
        cin >> mode;
        cin.ignore(); // 清除换行符

        if (mode == 1) {
            // 文件输入模式
            cout << "请输入包含 C 语言代码的.c 文件名 (例如 code.c) :" << endl;
            string filename;
            getline(cin, filename);

            ifstream infile(filename);
            if (!infile.is_open()) {
                cerr << RED_TEXT << "无法打开文件 " << filename << RESET_TEXT <<
endl;
                continue; // 返回模式选择界面
            }

            cout << "读取文件内容并进行词法分析: " << endl;
            string line;
            int lineNumber = 0;
            while (getline(infile, line)) {
                lineNumber++;

```



```
processLine(line, lineNumber);
}

infile.close();
cout << "文件词法分析完成！" << endl;
}

else if (mode == 2) {
    // 控制台输入模式
    cout << "请输入包含单词的句子进行词法分析（输入 'quit' 退出该模式）：" <<
endl;

    int lineNumber = 0;
    while (true) {
        lineNumber++;
        cout << "> ";
        string input;
        getline(cin, input);
        if (input == "quit")
            break;
        processLine(input, lineNumber);
    }
}

else if (mode == 3) {
    cout << "程序退出！" << endl;
    break;
}

else {
    cout << RED_TEXT << "输入模式错误，请重新选择！" << RESET_TEXT << endl;
}

return 0;
}
```

说明：

主函数提供三种输入模式：文件输入、控制台输入和退出。

文件输入模式下，提示输入文件名，逐行读取文件并调用 `processLine` 处理，同时统计行号；

控制台输入模式下，用户可逐行输入源代码（输入 "quit" 退出该模式）；

如果用户输入的模式错误，则以红色显示错误信息。*



六. 实验数据、结果分析

1. 程序安装

打开以下任意一个安装包选择安装路径可正常安装程序。

LT词法分析.msi	2025/3/27 21:23	Windows Install...	1,320 KB
setup.exe	2025/3/27 21:23	应用程序	563 KB

选择安装文件夹



安装程序将把 LT词法分析 安装到下面的文件夹中。

要在该文件夹中进行安装，请单击“下一步”。要安装到其他文件夹，请在下面输入另一个文件夹或单击“浏览”。

文件夹(F) :

D:\THEFREEGAME\课程\大三下\词法分析安装\

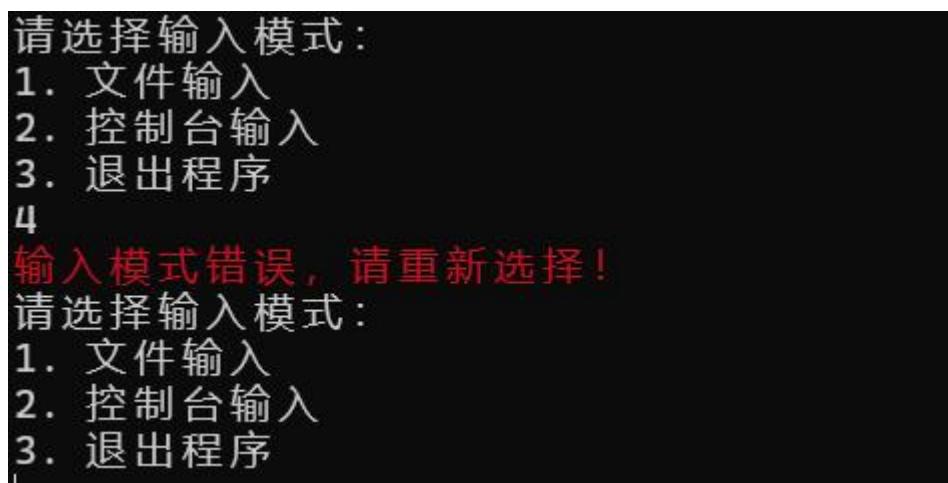
为自己还是为所有使用该计算机的人安装 LT词法分析:

- 任何人(E)
 只有我(M)

选择安装路径成功安装后桌面会有软件快捷方式



2. 打开程序测试输入



若输入错误则会报错并提醒重新输入。



2. 选择控制台输入并输入测试用例，正常跳过空白符并分析词素。

```
请选择输入模式：  
1. 文件输入  
2. 控制台输入  
3. 退出程序  
2  
请输入包含单词的句子进行词法分析（输入 'quit' 退出该模式）：  
> void main(){string _iijjkk123=2+1;  
[跳过 1 个空白符]  
[跳过 1 个空白符]  
种别码：101, 单词：void  
种别码：102, 单词：main  
种别码：302, 单词：  
种别码：303, 单词：  
种别码：304, 单词：  
种别码：400, 单词：string  
种别码：400, 单词：_iijjkk123  
种别码：205, 单词：  
种别码：500, 单词：2  
种别码：201, 单词：  
种别码：500, 单词：1  
种别码：301, 单词：  
种别码：305, 单词：  
>
```

3. 控制台输入无种别码词素，生成红色报错提示。

```
> "the dog == 2"  
[跳过 1 个空白符]  
[跳过 1 个空白符]  
[跳过 1 个空白符]  
[错误] 第 2 行：无法识别的词素 ' "  
种别码：400, 单词：the  
种别码：400, 单词：dog  
种别码：206, 单词：  
种别码：500, 单词：2  
[错误] 第 2 行：无法识别的词素 ' "
```

输入 quit 结束程序。

4. 测试文件输入，输入 1 选择文件输入模式

输入文件名，测试文件保存在软件目录下，是一个冒泡排序 C 语言程序。

```
请选择输入模式：  
1. 文件输入  
2. 控制台输入  
3. 退出程序  
1  
请输入包含C语言代码的.c文件名（例如 code.c）：  
code.c
```



名称	修改日期	类型	大小
code.c	2025/3/26 10:24	C source file	1 KB
liangTongLexicalAnalys.exe	2025/3/27 21:23	应用程序	218 KB
MSVCP140D.dll	2024/1/19 20:38	应用程序扩展	900 KB
ucrtbased.dll	2023/9/29 20:47	应用程序扩展	2,186 KB
VCRUNTIME140_1D.dll	2024/1/19 20:38	应用程序扩展	64 KB
VCRUNTIME140D.dll	2024/1/19 20:38	应用程序扩展	182 KB
软件图标.ico	2025/3/26 12:46	Icon File	67 KB
源.cpp	2025/3/27 21:06	C++ Source	9 KB

```
1 void Bubble_sort(int arr[], int size)
2 {
3     int j, i, tem;
4     for (i = 0; i < size-1; i++)
5         int count = 0;
6         for (j = 0; j < size-1 - i; j++)
7         {
8             if (arr[j] > arr[j+1])
9             {
10                 tem = arr[j];
11                 arr[j] = arr[j+1];
12                 arr[j+1] = tem;
13                 count = 1;
14             }
15         }
16     if (count == 0)
17         break;
```

按回车后程序正常分析词素和种别码，对于没有种别码的单词会进行红色字符报错，并提示错误在哪一行

```
1
请输入包含C语言代码的.c文件名 (例如 code.c) :
code.c
读取文件内容并进行词法分析:
[跳过 1 个空白符]
[跳过 1 个空白符]
[跳过 1 个空白符]
[跳过 1 个空白符]
种别码: 101, 单词: void
种别码: 400, 单词: Bubble_sort
种别码: 302, 单词: (
种别码: 103, 单词: int
种别码: 400, 单词: arr
种别码: 306, 单词: [
种别码: 307, 单词: ]
[错误] 第 1 行: 无法识别的词素 ','
种别码: 103, 单词: int
种别码: 400, 单词: size
种别码: 303, 单词: )

种别码: 304, 单词: {
[跳过 1 个空白符]
[跳过 1 个空白符]
```

```
种别码: 400, 单词: i
种别码: 211, 单词: ++
种别码: 303, 单词: )
[跳过 1 个空白符]
种别码: 304, 单词: {
[跳过 2 个空白符]
[跳过 1 个空白符]
种别码: 400, 单词: scanf
种别码: 302, 单词: (
[错误] 第 33 行: 无法识别的词素 '""'
[错误] 第 33 行: 无法识别的词素 '%'
种别码: 400, 单词: d
[错误] 第 33 行: 无法识别的词素 '""'
[错误] 第 33 行: 无法识别的词素 '/'
[错误] 第 33 行: 无法识别的词素 '&'
种别码: 400, 单词: arr
种别码: 306, 单词: [
种别码: 400, 单词: i
```

5. 输入 3 退出程序，打开任务管理器可观察程序停止运行。



七. 学习记录

1. 头歌平台学习记录

头歌平台实验 1

The screenshot shows a learning record for "What is lex/flex?". The code editor contains a Lex/Flex scanner definition. The main part of the code is:

```
/* begin */
/* end */

[a-zA-Z]*ab {printf("%s: Hit!\n", yytext);}
[0-9]+ {printf("get number:%s\n", yytext);}

.

%%

int yywrap() { return 1; }
int main(int argc, char **argv)
{
    if (argc > 1) {
        if (!(yyin = fopen(argv[1], "r")))
            perror(argv[1]);
    }
}
```

The code editor highlights the rule `[a-zA-Z]*ab {printf("%s: Hit!\n", yytext);}`. The test results show 1/1 tests passed, with expected output and actual output both showing "Helloab: Hit!".

测试用例全部通过

代码结构详解

头文件包含：

使用 `%{ ... %}` 块包含了 `<stdio.h>`, 以便使用 `printf` 函数输出结果。

词法规则区 (%% 内):

自定义代码区 (`begin` 和 `end` 之间): 此部分预留给用户扩展代码, 目前为空, 但可以添加额外的初始化或者辅助函数。

规则 `[a-zA-Z]*ab:`

匹配规则: `[a-zA-Z]*` 表示任意个字母 (大写或小写) 的序列, 后接固定的字符串 "ab" (要求必须是小写)。

动作: 匹配到的字符串存储在全局变量 `yytext` 中, 然后调用 `printf("%s: Hit!\n", yytext);` 输出匹配信息。

规则 `[0-9]+:`

匹配一串连续的数字, 并输出 "get number:" 后跟数字序列。

规则 `\n` 和 `.`:

用于处理换行符和其他所有未匹配的字符, 保证输入中的不合法部分不会干扰整体的扫描。

辅助函数:

`int yywrap() { return 1; }:` 表示当输入结束后, 词法分析器自动结束扫描。

主函数 `main`:

检查命令行参数, 如果提供了文件名, 则打开该文件作为输入。



使用 while (yylex()) 循环调用词法分析器 yylex(), 直到文件结束。

核心功能与注意点

核心功能:

合法输入识别: 代码核心在于 `[a-zA-Z]*ab` 规则, 这条规则确保只有以小写字母 “ab” 结尾的字符串才会输出 “Hit!”。

数字处理: 除了字符串, 还实现了对纯数字的识别。

注意点:

匹配优先级: 规则顺序决定了匹配优先级。此处首先匹配以 “ab” 结尾的字符串, 其次匹配数字, 最后通过 . 捕获其他不符合规则的字符。

扩展空间: begin 和 end 之间的区域可以用于添加额外代码, 例如状态控制或者更多匹配规则。

头歌平台实验 2

The screenshot shows a completed assignment titled "用LEX(FLEX)生成PL语言的词法分析器" (Using LEX(FLEX) to generate a lexical analyzer for PL language). The assignment details are as follows:

- 任务描述:
 - flex的语法以及使用规则
 - PL语言单词符号及其种别值
 - 识别PL单词的状态图
- 相关知识:

为了完成本关任务, 你需要掌握: flex的语法和使用规则。本教程会简略的介绍flex的相关知识, 没有涉及全部细节, 如果有想深入探究的同学, 可以参考flex2.5手册。
- 代码文件:

```
52 %%
53 %%
54 
55 {CHARCON}   {printf("%s: CHARCON\n", yytext);}
56 {PLUS}       {printf("%s: PLUS\n", yytext);}
57 {MINUS}      {printf("%s: MINUS\n", yytext);}
58 {TIMES}      {printf("%s: TIMES\n", yytext);}
59 {DIVSYM}     {printf("%s: DIVSYM\n", yytext);}
60 {EQ}          {printf("%s: EQ\n", yytext);}
61 {NEQ}         {printf("%s: NEQ\n", yytext);}
62 {LSS}         {printf("%s: LSS\n", yytext);}
63 {LEQ}         {printf("%s: LEQ\n", yytext);}
64 {GTR}         {printf("%s: GTR\n", yytext);}
65 {GEQ}         {printf("%s: GEQ\n", yytext);}
66 {LBRACK}     {printf("%s: LBRACK\n", yytext);}
67 {RBRACK}     {printf("%s: RBRACK\n", yytext);}

测试结果:  
5/5 全部通过
```

测试用例全部通过。

下面是一份对实验 2 PL 词法分析器代码的总结笔记 (不超过 400 字):

该代码使用 LEX/FLEX 构建了一个 PL 语言的词法分析器。程序分为两大部分: 定义 token 和匹配规则。首先在 “begin” 与 “end” 之间, 用宏定义形式声明了 PL 支持的各种关键字和符号, 如 OFSYM、ARRAYSYM、PROGRAMSYM、运算符 (PLUS、MINUS、TIMES、DIVSYM 等)、比较符号 (EQL、NEQ、LSS、LEQ、GTR、GEQ)、标点符号 (LBRACK、RBRACK、LPAREN、RPAREN、COMMA、SEMICOLON、COLON、PERIOD)、赋值符号 BECOME, 以及整型常量 INTCON、字符常量 CHARCON 和标识符 IDENT。最后还定义了一个 ERROR 规则用于捕获非法字符。

在 “%%” 部分, 每个 token 对应一个动作, 即当规则匹配时调用 printf 输出 token 种别和匹配文本。匹配顺序由上至下, 确保优先匹配关键字和多字符符号, 防止与单字符符号冲突。辅助规则\n 和. 分别处理换行符和其他未匹配字符, 保证词法分析的连贯性。最后, 通过 yywrap()



函数与 main 函数整合，实现对输入文件的扫描与词法分析。

此代码能识别完整的 PL 源程序，并在遇到非法字符时给出错误提示，适用于平台提供的五个测试集。

2. 程序中遇到的困难与解决思路

在开发这个词法分析器的过程中，遇到了一些挑战和挫折，下面列举几个主要的问题及其解决方案：

分词规则的设计

困难：最开始设计分词时，如何将连续的字符正确拆分成单个词素（如将 "a=2-1;" 分成 "a", "=", "2", "-", "1", ";"），确保每种类型（标识符、数字、运算符、界符）都能被正确识别，是个较为复杂的问题。

解决方案：经过查阅相关编译原理资料，我们采用了逐字符扫描的方式，依次判断字符类型，并对连续的空白符进行统计提示。为此设计了 tokenizeLine 函数，通过精细的条件判断（例如对字母、数字、运算符、界符的不同处理）来实现正确分词。通过多次调试与测试（使用控制台和文件输入模式分别验证），不断修正了判断条件，最终获得了较为准确的分词效果。

标识符和数字常量识别的模糊性

困难：在 C 语言中，标识符的规则允许数字出现在非首字符位置，而数字常量的格式可能和标识符混淆（例如 "123abc" 既不符合标识符也不是合法数字）。

解决方案：通过细致阅读教材和实验指导书，我们修改了 analyzeToken 函数中对标识符和数字的判断逻辑，允许标识符包含数字但要求首字符必须是字母或下划线。同时，对数字常量的处理增加了对小数点和科学计数法的判断，并设置了合适的条件，确保两者区分明确。

错误处理与反馈设计

困难：在实验要求中，错误提示要求必须显示行号，并且错误信息需要以红色显示。如何在控制台中实现彩色输出一开始没有明确思路。

解决方案：通过搜索 ANSI 终端颜色代码，我们了解到使用 \033[31m 可以将文本显示为红色，而 \033[0m 可以重置颜色。于是我们在输出错误信息的地方增加了这两个宏定义 (RED_TEXT 和 RESET_TEXT)，确保在检测到无法识别的词素时，能够正确输出红色错误提示，并且显示错误的行号。

文件输入和控制台输入模式的整合

困难：最初只实现了控制台输入模式，但在实验中需要支持文件输入，并且在文件扫描结束后还能选择其他模式。如何在设计上使程序既能处理文件，又能保持良好的用户交互体验，是一个设计挑战。

解决方案：我们在 main 函数中设计了一个循环菜单，让用户可以选择文件输入、控制台输入或退出程序。通过在文件输入模式中逐行读取代码、传递行号到 processLine 函数，并在结束后返回主菜单，从而实现了良好的模式切换。多次测试后，确保各个模式均能正确运行并且互不干扰。



调试和测试

困难：由于词法分析器涉及多种情况（包括边界条件、错误输入等），在实际运行中发现部分边界情况无法正确识别，如连续空格、含有非法字符的词素等。

解决方案：针对这些问题，我们设计了一系列测试用例（包括正确输入和错误输入），在文件和控制台两种模式下反复测试，通过调试输出逐步查找问题所在，并及时修改代码逻辑，最终使得所有测试用例都能达到预期效果。

八. 实验小结

通过本次实验，我深入理解了词法分析器的核心原理，掌握了正规表达式、状态转换图和模块化设计等关键知识。在设计与实现过程中，我将输入处理、分词、词法识别和错误检测模块化，保证了代码结构清晰且便于扩展。调试过程中，通过反复查阅资料和测试，我解决了标识符与数字常量识别模糊、连续空白符处理等问题，显著提升了调试和测试能力。软件不仅支持控制台输入，还增加了文件输入功能，并实现了行号跟踪与错误提示（以红色显示），改善了用户体验。此次实验不仅巩固了理论知识，更使我对实际编译器前端设计有了初步认识，为今后更复杂的编译器设计打下坚实基础。